



ΑΡΙΣΤΟΤΕΛΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΟΝΙΚΗΣ

Σχολή Θετικών Επιστημών

Τμήμα Φυσικής

**Ερμηνεία των προβλέψεων νευρωνικών δικτύων
για την απόδοση αναλογικών κυκλωμάτων
με χρήση τιμών SHAP**

Πτυχιακή Εργασία

του

Δεββέ Μιχάλη

Επιβλέπων Θωμάς Νούλης

23 Σεπτεμβρίου 2025

– Η σελίδα αυτή έχει αφεθεί σκόπιμα κενή –

Ευχαριστίες

Θα ήθελα να ευχαριστήσω θερμά τον επιβλέποντα της εργασίας μου, κ. Θωμά Νούλη, για την καθοδήγηση, την εμπιστοσύνη και τις ουσιαστικές παρατηρήσεις του σε όλα τα στάδια της μελέτης. Η συμβολή του υπήρξε καθοριστική για τη διαμόρφωση του θέματος και την επιτυχή ολοκλήρωση της εργασίας.

Ιδιαίτερες ευχαριστίες οφείλω στην Ελένη Παπαγεωργίου για τη σημαντική βοήθεια που μου προσέφερε, τις γόνιμες συζητήσεις και τις εύστοχες υποδείξεις της κατά την πορεία της έρευνας και της συγγραφής.

Τέλος, εκφράζω την ειλικρινή μου ευγνωμοσύνη προς την οικογένεια και τους φίλους μου για την αδιάκοπη συμπαράσταση, την υπομονή και την ενθάρρυνση σε όλη τη διάρκεια των σπουδών μου.

Περίληψη

Η παρούσα εργασία εξετάζει την πρόβλεψη βασικών μετρικών απόδοσης ενός τελεστικού ενισχυτή μέσω τεχνητού νευρωνικού δικτύου και τη συνακόλουθη ερμηνεία των προβλέψεων με μεθόδους εξηγούμενης τεχνητής νοημοσύνης. Υλοποιείται πλήρως συνδεδεμένο νευρωνικό δίκτυο στο PyTorch, το οποίο εκπαιδεύεται σε σύνολο δεδομένων με πέντε παραμέτρους εισόδου και οκτώ μετρικές εξόδου. Η προεπεξεργασία περιλαμβάνει κανονικοποίηση χαρακτηριστικών και διαχωρισμό σε σύνολα εκπαίδευσης/ελέγχου, ενώ η εκπαίδευση πραγματοποιείται με Adam και συνάρτηση κόστους MSE. Η αξιολόγηση στο σύνολο ελέγχου δείχνει καλή προσαρμογή ($R^2 \approx 0.91$, $MSE = 0.0078$, $RMSE = 0.0883$), επιβεβαιώνοντας την ικανότητα του μοντέλου να αποτυπώνει μη γραμμικές σχέσεις ανάμεσα σε σχεδιαστικές παραμέτρους και μετρικές απόδοσης.

Για την ερμηνεία εφαρμόζονται τιμές SHAP (Kernel Explainer), οι οποίες ποσοτικοποιούν τη συνεισφορά κάθε εισόδου στην τελική πρόβλεψη. Τα αποτελέσματα αναδεικνύουν διακριτούς ρόλους των παραμέτρων: η Cc εμφανίζεται καθοριστική για μετρικές όπως Unity Gain και Slew Rate, η Wbp κυριαρχεί σε ICMR_max και μέγιστη τάση εξόδου, ενώ οι Wdiff και Wnb επηρεάζουν πρωτίστως το ICMR_min και την ελάχιστη τάση εξόδου. Η συνδυασμένη χρήση πρόβλεψης και ερμηνευσιμότητας προσφέρει σαφή πλεονεκτήματα έναντι αποκλειστικής προσφυγής σε χρονοβόρες προσομοιώσεις SPICE, ιδίως σε σενάρια ταχείας βελτιστοποίησης σχεδιασμού.

Συνολικά, η προσέγγιση καταδεικνύει ότι τα νευρωνικά δίκτυα, εμπλουτισμένα με μεθόδους ερμηνείας όπως οι τιμές SHAP, συνιστούν αποδοτικό και διαφανές εργαλείο για την ανάλυση και τον σχεδιασμό αναλογικών ολοκληρωμένων κυκλωμάτων.

Λέξεις-Κλειδιά: τεχνητά νευρωνικά δίκτυα, εξηγούμενη τεχνητή νοημοσύνη, SHAP, τελεστικοί ενισχυτές, αναλογικά ολοκληρωμένα κυκλώματα, PyTorch.

Πίνακας Περιεχομένων

Ευχαριστίες	3
Περίληψη	4
1 Εισαγωγή	7
2 Θεωρητικό Υπόβαθρο	9
2.1 Νευρωνικά Δίκτυα	9
2.2 Αναλογικά Ολοκληρωμένα Κυκλώματα	10
2.3 Ερμηνεία ΑΙ και SHAP	11
3 Μεθοδολογία	15
3.1 Δεδομένα	16
3.2 Αρχιτεκτονική Μοντέλου και Εκπαίδευση	16
3.2.1 Αρχιτεκτονική Νευρωνικού Δικτύου	17
3.2.2 Συνάρτηση Κόστους και Βελτιστοποίηση	18
3.2.3 Διαδικασία Εκπαίδευσης	18
3.2.4 Αξιολόγηση Μοντέλου	19
3.2.5 Ερμηνευσιμότητα με SHAP	19
3.3 Υπολογισμός και Ανάλυση Τιμών SHAP	20
4 Αποτελέσματα και Ανάλυση	21
5 Συμπεράσματα	33
6 Βιβλιογραφία	35

Κεφάλαιο 1

Εισαγωγή

Η πρόοδος της τεχνητής νοημοσύνης τα τελευταία χρόνια έχει επιτρέψει την εφαρμογή σύγχρονων τεχνικών μηχανικής μάθησης σε ευρύ φάσμα επιστημονικών και τεχνολογικών πεδίων. Μεταξύ αυτών, τα νευρωνικά δίκτυα ξεχωρίζουν για την ικανότητά τους να μαθαίνουν πολύπλοκες μη γραμμικές σχέσεις από δεδομένα και να επιτυγχάνουν υψηλή ακρίβεια σε προβλήματα πρόβλεψης.

Ένα ενδιαφέρον πεδίο εφαρμογής των νευρωνικών δικτύων είναι αυτό των αναλογικών ολοκληρωμένων κυκλωμάτων. Πλήθος πρόσφατων εργασιών έχουν δείξει ότι τα ANNs μπορούν να λειτουργήσουν ως ταχέα υποκατάστατα προσομοιώσεων (surrogate models[4]) για κρίσιμα υποκυκλώματα, να επιταχύνουν το device sizing[2] και να προβλέπουν επιδόσεις (π.χ. σε τελεστικούς ενισχυτές[1]) με υψηλή ακρίβεια, μειώνοντας σημαντικά το κόστος προσομοίωσης[1]. Συγκεκριμένα, έχουν παρουσιαστεί ANN-βασισμένα μακρομοντέλα για op-amps[1] με πολλαπλάσια ταχύτητα από τα αντίστοιχα SPICE χωρίς ουσιώδη απώλεια ακρίβειας, καθώς και πλαίσια ML-καθοδηγούμενης βελτιστοποίησης[3] που μαθαίνουν από δεδομένα προσομοιώσεων και κατευθύνουν αποτελεσματικά τον σχεδιασμό. Σε αυτό το πλαίσιο, η παρούσα εργασία εξερευνά τη θεωρητική και πρακτική σύνδεση ανάμεσα σε νευρωνικά δίκτυα και τελεστικούς ενισχυτές, με στόχο την πρόβλεψη της απόδοσης ενός τελεστικού ενισχυτή μέσω ενός κατάλληλα εκπαιδευμένου νευρωνικού δικτύου, και την ερμηνεία των προβλέψεων με τιμές SHAP.

Παρότι τα νευρωνικά δίκτυα παρουσιάζουν υψηλές επιδόσεις, η ερμηνευσιμότητα των αποφάσεών τους παραμένει περιορισμένη, κάτι που αποτελεί σημαντικό εμπόδιο σε κρίσιμες εφαρμογές. Για την αντιμετώπιση αυτού του ζητήματος, έχει αναπτυχθεί το πεδίο της εξηγούμενης τεχνητής νοημοσύνης (Explainable AI, XAI), το οποίο περιλαμβάνει μεθόδους που βοηθούν στην κατανόηση της λειτουργίας ενός μοντέλου και στην ανάδειξη των εισόδων που επηρεάζουν περισσότερο την έξοδο του.

Για να αντιμετωπιστεί αυτή η πρόκληση, στην εργασία χρησιμοποιούνται οι τιμές SHAP (SHapley Additive exPlanations), οι οποίες βασίζονται στη θεωρία παιγνίων και επιτρέπουν την ποσοτική αποτίμηση της συμβολής κάθε εισόδου στην τελική πρόβλεψη

του μοντελου.


Ο συνδυασμός της μοντελοποίησης μέσω νευρωνικών δικτύων και της ερμηνείας μέσω των τιμών SHAP εφαρμόζεται σε δεδομένα που σχετίζονται με τη λειτουργία ενός τελεστικού ενισχυτή. Μέσα από τη μελέτη αυτή επιχειρείται να αναδειχθούν οι κρίσιμοι παράγοντες που επηρεάζουν την απόδοση του κυκλώματος, καθώς και πόσο επηρεάζει ο κάθε παράγοντας το τελικό αποτέλεσμα.

Κεφάλαιο 2

Θεωρητικό Υπόβαθρο

2.1 Νευρωνικά Δίκτυα

Τα νευρωνικά δίκτυα συνιστούν μία ισχυρή κατηγορία υπολογιστικών μοντέλων στο πεδίο της μηχανικής μάθησης, με σκοπό την προσέγγιση πολύπλοκων, συχνά μη γραμμικών, σχέσεων μεταξύ εισόδων και εξόδων. Βασίζονται σε μια αρχιτεκτονική εμπνευσμένη από τη λειτουργία των βιολογικών νευρώνων, όπου το μοντέλο απαρτίζεται από διαδοχικά επίπεδα τεχνητών νευρώνων: το επίπεδο εισόδου, ένα ή περισσότερα κρυφά επίπεδα και το επίπεδο εξόδου. Κάθε τεχνητός νευρώνας πραγματοποιεί έναν γραμμικό μετασχηματισμό των εισόδων του, ακολουθούμενο από την εφαρμογή μιας μη γραμμικής συναρτήσεως ενεργοποίησης, όπως η ReLU, η sigmoid ή η tanh, με σκοπό την αύξηση της εκφραστικής ικανότητας του δικτύου[15].



Σχήμα 2.1: Αρχιτεκτονική ενός τυπικού νευρωνικού δικτύου [14].

Η διαδικασία εκπαίδευσης των νευρωνικών δικτύων περιλαμβάνει τη βελτιστοποίηση των παραμέτρων του μοντέλου, βάρους (weight) και μεροληψίας (bias) μέσω κατάλληλων αλγορίθμων, όπως η καθοδική κλίση (gradient descent) και η οπισθοδιάδοση του σφάλματος (backpropagation). Η εκπαίδευση αποσκοπεί στην ελαχιστοποίηση μιας προκαθορισμένης συνάρτησης κόστους, η οποία μετρά τη διαφορά μεταξύ των προβλέψεων του μοντέλου και των πραγματικών τιμών. Η εν λόγω προσέγγιση καθιστά τα νευρωνικά δίκτυα ιδιαίτερα ικανά στην επίλυση προβλημάτων υψηλής πολυπλοκότητας, για τα οποία οι παραδοσιακές τεχνικές παρουσιάζουν περιορισμούς.

Λόγω της ευελιξίας τους και της δυνατότητας αυτόματης εξαγωγής χαρακτηριστικών, τα νευρωνικά δίκτυα έχουν βρει εκτεταμένη εφαρμογή σε ένα ευρύ φάσμα επιστημονικών και τεχνολογικών πεδίων, όπως η αναγνώριση προτύπων, η επεξεργασία φυσικής γλώσσας, η ανάλυση εικόνας και η πρόβλεψη χρονοσειρών. Η συνεχής πρόοδος στον τομέα της υπολογιστικής ισχύος, ιδίως μέσω της χρήσης γραφικών επεξεργαστών (GPUs), έχει επιτρέψει την ανάπτυξη βαθύτερων και αποδοτικότερων αρχιτεκτονικών, ενισχύοντας σημαντικά την ακρίβεια και την εφαρμοσιμότητα των νευρωνικών δικτύων σε πραγματικά προβλήματα.

2.2 Αναλογικά Ολοκληρωμένα Κυκλώματα

Τα αναλογικά ολοκληρωμένα κυκλώματα αποτελούν βασικό υποσύνολο των ολοκληρωμένων κυκλωμάτων, με σκοπό την επεξεργασία αναλογικών σημάτων, δηλαδή σημάτων που μεταβάλλονται συνεχώς στο χρόνο και λαμβάνουν συνεχείς τιμές στο εύρος τους. Σε αντίθεση με τα ψηφιακά κυκλώματα, τα οποία χειρίζονται διακριτές λογικές καταστάσεις, τα αναλογικά κυκλώματα λειτουργούν με τάσεις ή ρεύματα που αναπαριστούν πραγματικά φυσικά μεγέθη. Κύριες δομικές μονάδες των αναλογικών κυκλωμάτων είναι οι ενισχυτές, τα φίλτρα, οι ταλαντωτές και οι διαμορφωτές, με τον τελεστικό ενισχυτή (Operational Amplifier, OpAmp) να αποτελεί έναν από τους σημαντικότερους και ευρύτερα χρησιμοποιούμενους δομικούς λίθους.

Η διαδικασία σχεδιασμού ολοκληρωμένων κυκλωμάτων ακολουθεί συνήθως διαδοχικά στάδια. Ξεκινά με τον καθορισμό των προδιαγραφών (specification definition), όπου προσδιορίζονται οι απαιτήσεις του κυκλώματος σε επίπεδο λειτουργίας και απόδοσης. Στη συνέχεια επιλέγεται η κατάλληλη τοπολογία (topology selection), ανάλογα με τις επιθυμητές επιδόσεις και τους περιορισμούς της τεχνολογίας υλοποίησης. Ακολουθεί το στάδιο της διαστασιολόγησης (circuit sizing), κατά το οποίο καθορίζονται οι τιμές των παραμέτρων των τρανζίστορ και των παθητικών στοιχείων, ώστε το κύκλωμα να ικανοποιεί τις προδιαγραφές. Το τελευταίο στάδιο είναι η φυσική υλοποίηση σε επίπεδο διάταξης (layout design), όπου σχεδιάζεται η γεωμετρία των στοιχείων στο ολοκληρωμένο κύκλωμα, λαμβάνοντας υπόψη φαινόμενα παρασιτικών χωρητικοτήτων και αντιστάσεων. Από τα παραπάνω στάδια, η παρούσα εργασία επικεντρώνεται στο

circuit sizing, το οποίο συνδέεται άμεσα με την πρόβλεψη και ανάλυση της απόδοσης των αναλογικών ολοκληρωμένων κυκλωμάτων.

Η σχεδίαση αναλογικών ολοκληρωμένων κυκλωμάτων απαιτεί υψηλή ακρίβεια, καθώς ακόμη και μικρές αποκλίσεις στις παραμέτρους των τρανζίστορ ή στις τιμές των παθητικών στοιχείων μπορεί να επηρεάσουν σημαντικά τη συνολική συμπεριφορά του κυκλώματος. Επιπλέον, παράγοντες όπως η κατανάλωση ισχύος, ο θερμικός θόρυβος, η γραμμικότητα και το εύρος ζώνης αποτελούν κρίσιμα σημεία κατά τη διαδικασία σχεδιασμού. Για την εκτίμηση της απόκρισης τέτοιων κυκλωμάτων, χρησιμοποιούνται ευρέως εργαλεία αναλυτικής προσομοίωσης, με το SPICE (Simulation Program with Integrated Circuit Emphasis) [16] να αποτελεί το καθιερωμένο πρότυπο. Το SPICE υλοποιεί αριθμητικές μεθόδους επίλυσης μη γραμμικών διαφορικών εξισώσεων, οι οποίες προκύπτουν από το κύκλωμα, και επιτρέπει τον υπολογισμό της μεταβατικής απόκρισης (transient), δηλαδή της χρονικής συμπεριφοράς του κυκλώματος όταν εφαρμόζονται σήματα εισόδου, της DC απόκρισης (στατικό σημείο λειτουργίας και σαρώσεις DC) και της AC απόκρισης (συμπεριφορά ως προς τη συχνότητα, κέρδος και φάση). Η ακρίβεια της προσομοίωσης εξαρτάται σε μεγάλο βαθμό από τα μοντέλα των στοιχείων που χρησιμοποιούνται· για τα MOSFET, για παράδειγμα, εφαρμόζονται εκτενώς τα πρότυπα BSIM (Berkeley Short-channel IGFET Model) [17] που περιγράφουν λεπτομερώς τα φαινόμενα μικροκλίμακας, όπως οι χωρητικότητες διάχυσης, οι παρασιτικές αντιστάσεις και τα φαινόμενα βραχέος καναλιού. Παρότι οι προσομοιώσεις τύπου SPICE προσφέρουν υψηλή ακρίβεια, είναι συχνά υπολογιστικά δαπανηρές, ιδιαίτερα όταν το κύκλωμα περιλαμβάνει μεγάλο αριθμό τρανζίστορ ή απαιτείται εκτεταμένη ανάλυση παραμετρικών μεταβολών. Σε τέτοιες περιπτώσεις, η προσομοίωση μπορεί να χρειαστεί από λεπτά έως και ώρες για ένα μόνο σενάριο λειτουργίας, γεγονός που καθιστά δύσκολη την ενσωμάτωσή της σε διαδικασίες ταχείας βελτιστοποίησης.

Για τον λόγο αυτό, τα τελευταία χρόνια εξετάζεται η αξιοποίηση τεχνικών τεχνητής νοημοσύνης — όπως τα νευρωνικά δίκτυα — ως εναλλακτική ή συμπληρωματική μέθοδος πρόβλεψης της συμπεριφοράς αναλογικών κυκλωμάτων, επιτρέποντας ταχύτερη εκτίμηση επιδόσεων και καλύτερη κατανόηση των παραγόντων που επηρεάζουν την απόκρισή τους.

2.3 Ερμηνεία AI και SHAP

Καθώς τα μοντέλα τεχνητής νοημοσύνης — και ιδιαίτερα τα βαθιά νευρωνικά δίκτυα — εφαρμόζονται ολοένα και συχνότερα σε τομείς υψηλής σημασίας, όπως η ιατρική διάγνωση [5], τα αυτόνομα συστήματα [6] και η ανάλυση χρηματοοικονομικών δεδομένων [7], αναδεικνύεται η ανάγκη για ερμηνεύσιμες και διαφανείς αποφάσεις. Παρά τις υψηλές επιδόσεις τους, τα μοντέλα αυτά συχνά λειτουργούν ως «μαύρα κουτιά», καθιστώντας δυσχερή την κατανόηση των εσωτερικών τους μηχανισμών και των παραγόντων

που οδηγούν σε μια συγκεκριμένη πρόβλεψη ή σύσταση. Το πεδίο της εξηγούμενης τεχνητής νοημοσύνης (Explainable Artificial Intelligence, XAI) επιχειρεί να γεφυρώσει αυτό το χάσμα, αναπτύσσοντας μεθόδους που καθιστούν κατανοητή τη συμπεριφορά των αλγορίθμων, τόσο σε ολικό όσο και σε τοπικό επίπεδο.

Μία από τις πλέον καθιερωμένες και θεωρητικά θεμελιωμένες τεχνικές στο πλαίσιο της XAI είναι η μέθοδος SHAP (SHapley Additive exPlanations). Η προσέγγιση αυτή βασίζεται στη θεωρία παιγνίων, όπου κάθε χαρακτηριστικό εισόδου αντιμετωπίζεται ως «παίκτης» σε ένα συνεργατικό παιχνίδι και ο στόχος είναι να κατανείμουμε δίκαια την «απόδοση» (δηλαδή την πρόβλεψη του μοντέλου) μεταξύ όλων των παικτών. Συγκεκριμένα, η τιμή Shapley ενός χαρακτηριστικού i ορίζεται ως η μέση οριακή συμβολή του όταν προστίθεται σε όλους τους δυνατούς συνδυασμούς υποσυνόλων χαρακτηριστικών $S \subseteq N \setminus i$:

$$\phi_i(f) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [f(S \cup \{i\}) - f(S)],$$

όπου N είναι το σύνολο όλων των χαρακτηριστικών και $f(S)$ η έξοδος του μοντέλου όταν μόνο τα χαρακτηριστικά του υποσυνόλου S είναι διαθέσιμα.

Η παραπάνω φόρμουλα εξασφαλίζει ορισμένες θεμελιώδεις ιδιότητες, όπως αποδοτικότητα (το άθροισμα όλων των ϕ_i ισούται με την πραγματική πρόβλεψη του μοντέλου), συμμετρία (χαρακτηριστικά με ίδια συμβολή λαμβάνουν ίδιες τιμές), απουσία (χαρακτηριστικά που δεν επηρεάζουν την έξοδο έχουν τιμή μηδέν) και γραμμικότητα (αν το μοντέλο είναι γραμμικός συνδυασμός, οι Shapley values αθροίζονται) [18, 19].

Οι τιμές SHAP υπολογίζονται με βάση τη μέση οριακή συμβολή κάθε χαρακτηριστικού σε όλους τους δυνατούς συνδυασμούς εισόδων και παρέχουν μια συνεπή, μαθηματικά αιτιολογημένη αποτίμηση της σημασίας των μεταβλητών. Η εφαρμογή της μεθόδου SHAP επιτρέπει την κατανόηση του τρόπου με τον οποίο το μοντέλο λαμβάνει τις αποφάσεις του, ενισχύει τη διαφάνεια και την εμπιστοσύνη των χρηστών, και συμβάλλει στην εντοπισμό πιθανών προκαταλήψεων, ανωμαλιών ή περιοχών του χώρου εισόδου όπου το μοντέλο συμπεριφέρεται απροσδόκητα. Σε εφαρμογές όπου απαιτείται υψηλή αξιοπιστία και επεξηγηματικότητα, όπως η ανάλυση ηλεκτρονικών κυκλωμάτων, η ενσωμάτωση τεχνικών όπως οι SHAP προσφέρει σημαντικό πλεονέκτημα τόσο σε επίπεδο κατανόησης όσο και σε διαδικασίες βελτιστοποίησης σχεδίασης. Ωστόσο, οι τιμές Shapley είναι τόσο αξιόπιστες όσο και τα δεδομένα στα οποία βασίζονται· εάν τα δεδομένα εκπαίδευσης δεν περιλαμβάνουν επαρκείς παρατηρήσεις για να αποτυπώσουν την επίδραση ενός χαρακτηριστικού, η συμβολή του μπορεί να υποεκτιμηθεί ή να παραμορφωθεί. Επιπλέον, η διαδικασία υπολογισμού των Shapley values, που συχνά βασίζεται σε sampling από όλους τους δυνατούς συνδυασμούς εισόδων, περιορίζεται από την κατανομή και την πυκνότητα των δεδομένων στον χώρο εισόδου. Έτσι, περιοχές του χώρου εισόδου που δεν καλύπτονται επαρκώς οδηγούν σε λιγότερο ακριβείς εκτιμήσεις, ενώ ισχυρές εξαρτήσεις ή σπάνιες συνθήκες μπορεί να μην αναδειχθούν

πλήρως. Συνολικά, η αξιοπιστία των Shapley values συνδέεται στενά με την ποιότητα, την ποικιλία και την πυκνότητα των δεδομένων εκπαίδευσης.

Μία ιδιαίτερα διαδεδομένη υλοποίηση της μεθόδου SHAP είναι ο Kernel Explainer [20, 21]. Πρόκειται για έναν αλγόριθμο που επιτρέπει τον προσεγγιστικό υπολογισμό των τιμών Shapley για οποιοδήποτε μοντέλο, ανεξάρτητα από την εσωτερική του δομή, αντιμετωπίζοντας το ως «μαύρο κουτί». Ο Kernel Explainer βασίζεται σε μια τεχνική στάθμισης μέσω πυρήνα (kernel weighting), όπου δειγματοληπτούνται διαφορετικοί συνδυασμοί χαρακτηριστικών και στη συνέχεια εκτιμάται η συμβολή κάθε χαρακτηριστικού στην πρόβλεψη με χρήση μιας γραμμικής παλινδρόμησης βαρών.

Μαθηματικά, ο Kernel Explainer προσεγγίζει την πρόβλεψη του αρχικού μοντέλου $f(x)$ μέσω ενός γραμμικού ερμηνευτικού μοντέλου της μορφής:

$$f(x) \approx g(z') = \phi_0 + \sum_{j=1}^M \phi_j z'_j,$$

όπου z'_j είναι δυαδικές μεταβλητές που υποδεικνύουν την παρουσία ή απουσία του χαρακτηριστικού j , ενώ οι συντελεστές ϕ_j αντιπροσωπεύουν τις αντίστοιχες τιμές SHAP. Η τιμή ϕ_0 αντιστοιχεί στη μέση πρόβλεψη του μοντέλου όταν καμία είσοδος δεν είναι διαθέσιμη.

Η στάθμιση των διαφορετικών υποσυνόλων χαρακτηριστικών επιτυγχάνεται μέσω μιας συνάρτησης πυρήνα (kernel function), η οποία δίνει σε κάθε υποσύνολο βάρος:

$$\pi_z = \frac{(M - 1)}{\binom{M}{|z'|} |z'| (M - |z'|)},$$

όπου M είναι το πλήθος των συνολικών χαρακτηριστικών και $|z'|$ το μέγεθος του συγκεκριμένου υποσυνόλου. Με αυτόν τον τρόπο, τα υποσύνολα που περιλαμβάνουν περισσότερα χαρακτηριστικά και προσεγγίζουν καλύτερα το πλήρες σύνολο εισόδων λαμβάνουν μεγαλύτερη βαρύτητα, διασφαλίζοντας ότι η παλινδρόμηση παραμένει πιστή στη συμπεριφορά του αρχικού μοντέλου.

Ο όρος kernel αναφέρεται σε μια μαθηματική συνάρτηση βαρύτητας, η οποία καθορίζει πόσο σημαντικό θεωρείται κάθε υποσύνολο χαρακτηριστικών κατά τον υπολογισμό. Στην πράξη, τα υποσύνολα που μοιάζουν περισσότερο με το πλήρες σύνολο εισόδων λαμβάνουν μεγαλύτερο βάρος, ενώ εκείνα με λίγα χαρακτηριστικά μικρότερο. Με αυτόν τον τρόπο, η παλινδρόμηση ευθυγραμμίζεται με την πραγματική συμπεριφορά του μοντέλου, οδηγώντας σε πιο αξιόπιστη εκτίμηση των Shapley values.

Η μέθοδος αυτή έχει το πλεονέκτημα ότι μπορεί να εφαρμοστεί σε οποιοδήποτε αλγόριθμο μηχανικής μάθησης, χωρίς να απαιτείται γνώση ή τροποποίηση των εσωτερικών του μηχανισμών. Ωστόσο, το υπολογιστικό της κόστος εξαρτάται έντονα από το πλήθος των χαρακτηριστικών, καθώς ο αριθμός των απαραίτητων δειγματοληψιών

αυξάνεται εκθετικά. Παρά τον περιορισμό αυτό, ο Kernel Explainer χρησιμοποιείται ευρέως στην πράξη λόγω της ευελιξίας και της θεωρητικής εγκυρότητας που παρέχει, αποτελώντας βασικό εργαλείο για την κατανόηση και την επεξήγηση πολύπλοκων μοντέλων σε πραγματικά δεδομένα.

Πέρα από τη μέθοδο SHAP, στο πεδίο της εξηγούμενης τεχνητής νοημοσύνης έχουν αναπτυχθεί και άλλες ευρέως χρησιμοποιούμενες τεχνικές ερμηνευσιμότητας. Ενδεικτικά, η μέθοδος LIME (Local Interpretable Model-agnostic Explanations) [8] παρέχει τοπικές γραμμικές προσεγγίσεις γύρω από κάθε πρόβλεψη του μοντέλου, επιτρέποντας την κατανόηση των χαρακτηριστικών που επηρεάζουν μια συγκεκριμένη απόφαση. Μία ακόμη κατηγορία περιλαμβάνει τις μεθόδους βασισμένες σε συναρτήσεις ευαισθησίας και παραγώγων, όπως το Integrated Gradients [9], το οποίο κατανέμει την πρόβλεψη στα χαρακτηριστικά εισόδου μέσω της ολοκλήρωσης των κλίσεων κατά μήκος μιας διαδρομής από ένα σημείο αναφοράς. Επιπλέον, οι τεχνικές οπτικοποίησης όπως το Grad-CAM [10] έχουν ιδιαίτερη εφαρμογή σε συνελκτικά νευρωνικά δίκτυα, καθώς αποκαλύπτουν ποιες περιοχές της εικόνας συμβάλλουν περισσότερο στην πρόβλεψη.

Οι διαφορετικές αυτές προσεγγίσεις αναδεικνύουν το ευρύ φάσμα εργαλείων που είναι διαθέσιμα στο πεδίο της XAI, το καθένα με πλεονεκτήματα και περιορισμούς ανάλογα με τον τύπο του μοντέλου και το πεδίο εφαρμογής. Στην παρούσα εργασία, επιλέγεται η χρήση του SHAP, καθώς παρέχει θεωρητικά θεμελιωμένη και συνεπή κατανομή της συμβολής των εισόδων στις εξόδους, είναι ανεξάρτητο από τον τύπο του μοντέλου και μπορεί να εφαρμοστεί αποτελεσματικά σε πολυμεταβλητά προβλήματα παλινδρόμησης.

Μεθοδολογία

The diagram illustrates a two-stage CMOS operational amplifier. The first stage is a differential pair consisting of NMOS transistors M_1 and M_2 (labeled W_{diff}) and PMOS transistors M_3 and M_4 (labeled W_{nb}). The second stage is a common-source amplifier with NMOS transistor M_5 (labeled W_{bp}) and PMOS transistors M_6 and M_7 (labeled W_{bp} and W_{po} respectively). A current source I_0 is connected to the gates of M_5 and M_6 . A compensation capacitor C_c is connected between the output of the first stage and the gate of M_5 . The output of the second stage is connected to a load capacitor C_L . The circuit is powered by V_{DD} and V_{SS} .

15

3.1 Δεδομένα

Στον Πίνακα 3.1 παρουσιάζονται αναλυτικά οι παράμετροι και οι μετρικές απόδοσης του κυκλώματος.

Πίνακας 3.1: Παράμετροι και Μετρικές Απόδοσης του κυκλώματος

Κατηγορία	Συντομογραφία	Πλήρες Όνομα / Περιγραφή
Παράμετροι	Cc	Χωρητικότητα σύζευξης (Coupling Capacitor)
	Wbp	Πλάτος τρανζίστορ biasing point
	Wdiff	Πλάτος διαφορικού ζεύγους
	Wnb	Πλάτος negative bias / NMOS
	Wpo	Πλάτος positive output / PMOS
Μετρικές Απόδοσης	PM	Phase Margin
	UGBW	Unity Gain Bandwidth
	G	Κέρδος (Gain)
	ICMR_max	Μέγιστη Input Common-Mode
	ICMR_min	Ελάχιστη Input Common-Mode
	Vout_max	Μέγιστη τάση εξόδου
	Vout_min	Ελάχιστη τάση εξόδου
	SR	Slew Rate

Η αρχική μορφή των δεδομένων ήταν αρχείο CSV, το οποίο φορτώθηκε με χρήση της βιβλιοθήκης pandas [11].

Η επεξεργασία των δεδομένων περιλάμβανε:

1. **Έλεγχος πληρότητας και συνέπειας:** Διασφαλίστηκε ότι δεν υπάρχουν ελλείψεις ή μη έγκυρες τιμές, οι οποίες θα μπορούσαν να επηρεάσουν την εκπαίδευση.
2. **Κανονικοποίηση χαρακτηριστικών:** Εφαρμόστηκε Standard Scaling, της βιβλιοθήκης scikit-learn [22] (μηδενικός μέσος όρος και μοναδιαία τυπική απόκλιση) τόσο στις εισόδους όσο και στις εξόδους. Η κανονικοποίηση μειώνει την πιθανότητα αριθμητικής αστάθειας κατά τη βελτιστοποίηση και εξισώνει την κλίμακα των χαρακτηριστικών.
3. **Διαχωρισμός σε υποσύνολα:** Το σύνολο δεδομένων χωρίστηκε σε **σύνολο εκπαίδευσης** (80%) και **σύνολο ελέγχου** (20%) με χρήση σταθερού τυχαίου σπόρου (random state) για αναπαραγωγιμότητα.

3.2 Αρχιτεκτονική Μοντέλου και Εκπαίδευση

Η αρχιτεκτονική του νευρωνικού δικτύου σχεδιάστηκε με στόχο την πρόβλεψη οκτώ μετρικών απόδοσης αναλογικών κυκλωμάτων, με βάση πέντε παραμέτρους εισόδου.

Η υλοποίηση πραγματοποιήθηκε στο περιβάλλον PyTorch [12] και βασίζεται σε ένα πλήρως συνδεδεμένο feed-forward δίκτυο.

3.2.1 Αρχιτεκτονική Νευρωνικού Δικτύου

Το δίκτυο αποτελείται από :

- Ένα επίπεδο εισόδου πέντε διαστάσεων,
- Δύο κρυφά επίπεδα πλήρως συνδεδεμένων νευρώνων (fully connected layers) με δέκα μονάδες το καθένα,
- Μία συνάρτηση ενεργοποίησης Rectified Linear Unit (ReLU) μετά το πρώτο κρυφό επίπεδο και μία ακόμη ReLU μετά το δεύτερο κρυφό επίπεδο,
- Ένα επίπεδο εξόδου οκτώ διαστάσεων, το οποίο αντιστοιχεί στις μετρικές απόδοσης του κυκλώματος.

Η διαδικασία της προώθησης (forward pass) περιγράφεται ως εξής :

$$x \longrightarrow \text{Linear}(5, 10) \longrightarrow \text{ReLU} \longrightarrow \text{Linear}(10, 10) \longrightarrow \text{ReLU} \longrightarrow \text{Linear}(10, 8) \longrightarrow \hat{y}$$

Σημείωση: Στο συγκεκριμένο μοντέλο παρεμβάλλεται συνάρτηση ενεργοποίησης και ανάμεσα στα δύο κρυφά πλήρως συνδεδεμένα επίπεδα. Έτσι, το δίκτυο αποκτά μεγαλύτερη μη-γραμμικότητα και εκφραστική ικανότητα, χωρίς να παρουσιάζει αστάθεια κατά την εκπαίδευση. Η επιλογή αυτή βελτίωσε τη γενίκευση του μοντέλου και οδήγησε σε ικανοποιητικά αποτελέσματα στα πειράματα ($R^2 \approx 0.91$).

Η χρήση της συνάρτησης ReLU συμβάλλει στην αποφυγή του προβλήματος vanishing gradients. Το φαινόμενο αυτό εμφανίζεται όταν χρησιμοποιούνται συναρτήσεις ενεργοποίησης με περιορισμένο εύρος τιμών, όπως η sigmoid ή η tanh, με αποτέλεσμα οι παράγωγοι που μεταφέρονται προς τα πίσω κατά τον αλγόριθμο της οπισθοδιάδοσης (backpropagation) να γίνονται εξαιρετικά μικρές. Όσο αυξάνεται το βάθος του δικτύου, οι πολύ μικρές αυτές τιμές τείνουν να μηδενίζονται, με συνέπεια η εκπαίδευση να επιβραδύνεται ή να «παγώνει», καθώς τα βάρη των πρώτων επιπέδων δεν ενημερώνονται επαρκώς.

Η ReLU, αντίθετα, διατηρεί μη μηδενική παράγωγο για όλες τις θετικές εισόδους, επιτρέποντας σταδιακά μεγαλύτερη ροή πληροφορίας προς τα πίσω και διευκολύνοντας τη βελτιστοποίηση. Έτσι, η σύγκλιση επιτυγχάνεται ταχύτερα και το δίκτυο μπορεί να μάθει αποτελεσματικότερα πολύπλοκα πρότυπα.

3.2.2 Συνάρτηση Κόστους και Βελτιστοποίηση

Για την εκπαίδευση του μοντέλου χρησιμοποιείται η συνάρτηση κόστους του μέσου τετραγωνικού σφάλματος (Mean Squared Error, MSE):


$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Η βελτιστοποίηση των παραμέτρων πραγματοποιείται με τον αλγόριθμο Adam [13], ο οποίος επελέγη λόγω της αποδοτικότητάς του στη σύγκλιση σε πολύπλοκα προβλήματα. Ο ρυθμός μάθησης τέθηκε ίσος με 0.001.

3.2.3 Διαδικασία Εκπαίδευσης

Το δίκτυο εκπαιδεύτηκε για 3000 εποχές, με ενημέρωση των βαρών μέσω back-propagation. Για την εκπαίδευση χρησιμοποιήθηκαν 837 δείγματα (80% για εκπαίδευση και 20% για έλεγχο), όπου κάθε δείγμα αντιστοιχεί σε έναν συνδυασμό πέντε παραμέτρων εισόδου και οκτώ μετρικών απόδοσης. Η πορεία του σφάλματος παρακολουθείται μέσω της εκτύπωσης της τιμής της συνάρτησης κόστους (Mean Squared Error loss) ανά 100 εποχές. Αυτό υλοποιείται στον βρόχο εκπαίδευσης με συνθήκη ελέγχου, η οποία ενεργοποιεί την εντολή print και εμφανίζει το τρέχον σφάλμα στην οθόνη. Έτσι, δίνεται στον χρήστη η δυνατότητα να παρακολουθεί σε πραγματικό χρόνο την εξέλιξη της σύγκλισης και να εντοπίζει πιθανές αστάθειες ή προβλήματα υπερεκπαίδευσης.

Κατά τη διάρκεια της εκπαίδευσης καταγράφεται η πορεία του σφάλματος (training loss) σε κάθε εποχή, ενώ παράλληλα δημιουργείται η αντίστοιχη καμπύλη σύγκλισης. Στο Σχήμα 3.2 παρουσιάζεται η μεταβολή της τιμής της συνάρτησης κόστους (MSE) ως προς τον αριθμό των εποχών. Παρατηρείται ταχεία μείωση του σφάλματος στις πρώτες εκατοντάδες εποχές και σταδιακή σταθεροποίηση καθώς το μοντέλο συγκλίνει. Στο τέλος, το μοντέλο αποθηκεύεται σε αρχείο performance_model.pth, μαζί με τους κανονικοποιητές των εισόδων και εξόδων, ώστε να είναι δυνατή η αναπαραγωγή και αξιολόγηση των αποτελεσμάτων σε μελλοντικά δεδομένα.



Σχήμα 3.2: Καμπύλη σύγκλισης της συνάρτησης κόστους (MSE) κατά την εκπαίδευση του νευρωνικού δικτύου για 3000 εποχές.

3.2.4 Αξιολόγηση Μοντέλου

Η απόδοση του μοντέλου στο σύνολο ελέγχου αξιολογείται με χρήση τριών μετริกών:

- MSE (Mean Squared Error),
- RMSE (Root Mean Squared Error),
- Συντελεστής Προσδιορισμού R^2 .

Επιπλέον, δημιουργούνται διαγράμματα διασποράς (scatter plots) μεταξύ των πραγματικών και των προβλεπόμενων τιμών, προσφέροντας οπτική αξιολόγηση της επίδοσης του μοντέλου.

3.2.5 Ερμηνευσιμότητα με SHAP

Για την ανάλυση ερμηνευσιμότητας χρησιμοποιήθηκε η μέθοδος SHAP. Για κάθε μία από τις οκτώ εξόδους του μοντέλου, εφαρμόστηκε ο KernelExplainer, ο οποίος εκτιμά την επίδραση κάθε εισόδου στη διαμόρφωση της τελικής πρόβλεψης.

Τα αποτελέσματα παρουσιάζονται με τη μορφή summary plots, τα οποία παράγονται μέσω της βιβλιοθήκης SHAP [19], όπου αποτυπώνεται η σχετική σημασία των χαρακτηριστικών, καθώς και με πίνακες που περιλαμβάνουν το μέσο όρο και την τυπική απόκλιση των τιμών SHAP ανά χαρακτηριστικό. Η ανάλυση αυτή παρέχει ουσιαστική πληροφόρηση για τη συμβολή των εισόδων στις εξόδους, καθιστώντας εφικτή την κατανόηση της σχέσης μεταξύ των σχεδιαστικών παραμέτρων και της απόδοσης των αναλογικών κυκλωμάτων.

3.3 Υπολογισμός και Ανάλυση Τιμών SHAP

Η ερμηνεία των προβλέψεων πραγματοποιήθηκε μέσω της μεθόδου SHAP, η οποία βασίζεται στη θεωρία παιγνίων και παρέχει ποσοτική εκτίμηση της συνεισφοράς κάθε χαρακτηριστικού στην τελική πρόβλεψη. Η μέθοδος αποδίδει σε κάθε είσοδο έναν Shapley value, που αναπαριστά τη μέση οριακή συμβολή της εισόδου σε όλους τους δυνατούς συνδυασμούς χαρακτηριστικών.

Για την παρούσα εργασία επιλέχθηκε ο KernelExplainer, καθώς:

- Είναι ανεξάρτητος από τον τύπο και την αρχιτεκτονική του μοντέλου.
- Παρέχει συνεπή αποτελέσματα σε πολυμεταβλητά προβλήματα παλινδρόμησης.
- Μπορεί να εφαρμοστεί ξεχωριστά για κάθε έξοδο, κάτι απαραίτητο στη συγκεκριμένη μελέτη.

Η διαδικασία υλοποιήθηκε ως εξής:

1. Επιλογή **συνόλου αναφοράς** (background data) από 50 δείγματα του συνόλου εκπαίδευσης, ώστε να υπολογιστούν οι βασικές προβλέψεις του μοντέλου.
2. Επιλογή 100 δειγμάτων από το σύνολο ελέγχου για ανάλυση.
3. Για κάθε μία από τις 8 εξόδους, υπολογίστηκαν οι τιμές SHAP μέσω του KernelExplainer.
4. Δημιουργία summary plots που οπτικοποιούν τη σημασία και την κατανομή των τιμών SHAP για κάθε χαρακτηριστικό.
5. Υπολογισμός στατιστικών δεικτών (μέσου όρου και τυπικής απόκλισης) των τιμών SHAP ανά χαρακτηριστικό, με σκοπό την ποσοτική ιεράρχηση της σημασίας τους.

Η εφαρμογή των τιμών SHAP επιτρέπει την αναγνώριση των κρίσιμων εισόδων που επηρεάζουν περισσότερο τις επιδόσεις του τελεστικού ενισχυτή και ενισχύει τη διαφάνεια και την αξιοπιστία του προτεινόμενου μοντέλου.

Κεφάλαιο 4

Αποτελέσματα και Ανάλυση


Στην ενότητα αυτή παρουσιάζονται τα αποτελέσματα της πειραματικής διαδικασίας. Αρχικά αξιολογείται η επίδοση του μοντέλου στο σύνολο ελέγχου με τη χρήση κατάλληλων μετρικών και γραφημάτων. Στη συνέχεια, εξετάζεται η ερμηνευσιμότητα των προβλέψεων μέσω της μεθόδου SHAP, προκειμένου να αναδειχθεί η συμβολή των παραμέτρων εισόδου στις μετρικές απόδοσης των τελεστικών ενισχυτών.

Μετά την ολοκλήρωση της εκπαίδευσης, το μοντέλο αξιολογήθηκε στο σύνολο ελέγχου, όπου επιτεύχθηκαν τα εξής αποτελέσματα :

- Test Loss (MSE): 0.0078
- Root Mean Squared Error (RMSE): 0.0883
- **Συντελεστής προσδιορισμού (R^2): 0.9125**


Τα αποτελέσματα αυτά δείχνουν ότι το μοντέλο έχει καλή ικανότητα πρόβλεψης των μετρικών απόδοσης των τελεστικών ενισχυτών, με μικρό σφάλμα και υψηλή γραμμική συσχέτιση μεταξύ των πραγματικών και προβλεπόμενων τιμών.

Στο Σχήμα 4.1 παρουσιάζεται η διασπορά των πραγματικών έναντι των προβλεπόμενων τιμών για το σύνολο ελέγχου. Η κόκκινη διακεκομμένη γραμμή αναπαριστά την ιδανική αντιστοιχία ($y = x$), επιβεβαιώνοντας την καλή απόδοση του μοντέλου.



Σχήμα 4.1: Σύγκριση πραγματικών και προβλεπόμενων τιμών μετρικών απόδοσης στο σύνολο ελέγχου.

Για κάθε μία από τις 8 μετρικές απόδοσης, υπολογίστηκαν οι τιμές SHAP, οι οποίες απεικονίζονται στα αντίστοιχα summary plots. Από τα διαγράμματα αυτά (παρατίθενται παρακάτω), είναι φανερό ότι ορισμένα χαρακτηριστικά εισόδου έχουν μεγαλύτερη επιρροή στην πρόβλεψη συγκεκριμένων εξόδων. Στη συνέχεια, παρουσιάζεται η ερμηνεία των SHAP plots, με στόχο την αποσαφήνιση του τρόπου με τον οποίο τα επιμέρους χαρακτηριστικά επηρεάζουν τις εξόδους του μοντέλου. Η εφαρμογή των τιμών SHAP βελτιώνει την διαφάνεια του μοντέλου και βοηθά στην κατανόηση των σχέσεων μεταξύ εισόδων και εξόδων, κάτι κρίσιμο για τη βελτιστοποίηση και το σχεδιασμό των τελεστικών ενισχυτών.



Σχήμα 4.2: SHAP summary plot για την έξοδο του μοντέλου.

Στο σχήμα 4.2 στον κατακόρυφο άξονα (Y) απεικονίζονται τα χαρακτηριστικά εισόδου του μοντέλου, ταξινομημένα κατά φθίνουσα σειρά σημασίας, όπως αυτή προκύπτει από τη μέση απόλυτη τιμή των SHAP values. Στο παρόν διάγραμμα, η παράμετρος Cc εμφανίζει τη μεγαλύτερη επίδραση στις προβλέψεις του μοντέλου, ενώ η παράμετρος Wnb τη μικρότερη.

Στον οριζόντιο άξονα (X) παρουσιάζονται οι τιμές SHAP, οι οποίες εκφράζουν την κατεύθυνση και το μέγεθος της επίδρασης κάθε χαρακτηριστικού στην αναμενόμενη τιμή πρόβλεψης (expected value) του μοντέλου και όχι στην πραγματική τιμή-στόχο (label) που χρησιμοποιήθηκε κατά την εκπαίδευση. Θετικές τιμές υποδηλώνουν ότι το χαρακτηριστικό συμβάλλει σε αύξηση της πρόβλεψης, ενώ αρνητικές τιμές σε μείωση. Αξίζει να σημειωθεί ότι οι τιμές αυτές βρίσκονται σε κανονικοποιημένη κλίμακα (π.χ. στο εύρος περίπου $[-3, 3]$), καθώς το μοντέλο εκπαιδεύτηκε με κανονικοποιημένες εξόδους. Συνεπώς, η πραγματική επίδραση σε φυσικές μονάδες (π.χ. τάση εξόδου σε Volt) προκύπτει μέσω της αντίστροφης κανονικοποίησης, ώστε να εκφραστεί με ακρίβεια το μέγεθος της συμβολής κάθε παραμέτρου στην έξοδο του κυκλώματος. Ακολουθούν οι πίνακες με τις κανονικοποιημένες τιμές:

Πίνακας 4.1: Όρια κανονικοποίησης (Είσοδοι). Για κάθε παράμετρο: μ (μέση τιμή), σ (τυπική απόκλιση), $\min$ (ελάχιστη τιμή στο δείγμα), $\max$ (μέγιστη τιμή στο δείγμα) σε φυσικές μονάδες, και $\min z$, $\max z$ (αντίστοιχα όρια στον κανονικοποιημένο χώρο $z = \frac{x-\mu}{\sigma}$).


Παράμετρος	μ	σ	$\min$	$\max$	$\min z$	$\max z$
Cc	10.8529	4.58791	1	21	-2.15	2.21
Wbp	12.2895	4.22936	1	21	-2.67	2.06
Wdiff	2.37703	0.968894	0.3	4.3	-2.14	1.98
Wnb	7.33373	5.10487	1	21	-1.24	2.68
Wpo	27.3648	8.40894	10	41	-2.07	1.62

Πίνακας 4.2: Όρια κανονικοποίησης (Εξόδοι). Για κάθε μετρική: μ (μέση τιμή), σ (τυπική απόκλιση), $\min$ (ελάχιστη τιμή στο δείγμα), $\max$ (μέγιστη τιμή στο δείγμα) σε φυσικές μονάδες, και $\min z$, $\max z$ (αντίστοιχα όρια στον κανονικοποιημένο χώρο $z = \frac{x-\mu}{\sigma}$).

Μετρική	μ	σ	$\min$	$\max$	$\min z$	$\max z$
PM	57.5625	10.7359	24.4329	110.304	-3.09	4.91
UG	2.40996e+06	1.21153e+06	117490	9.12011e+06	-1.89	5.54
G	50.3403	13.0504	6.99648	62.3874	-3.32	0.923
ICMR_max	0.856777	0.0458681	0.509314	0.918	-7.58	1.33
ICMR_min	-0.288238	0.0543581	-0.397554	-0.157699	-2.01	2.4
Vout_max	0.791927	0.0206236	0.609689	0.817718	-8.84	1.25
Vout_min	-0.775584	0.0484074	-0.82882	-0.664045	-1.1	2.3
SR	3.25021	2.0628	0.996505	26.498	-1.09	11.3

Το χρώμα των σημείων αντιστοιχεί στην κανονικοποιημένη τιμή του χαρακτηριστικού: το μπλε αντιπροσωπεύει χαμηλές τιμές, ενώ το κόκκινο υψηλές. Η χρωματική κλιμάκωση επιτρέπει την ταυτόχρονη αξιολόγηση τόσο της σημασίας όσο και της πραγματικής τιμής κάθε χαρακτηριστικού, διευκολύνοντας την ερμηνεία της συμπεριφοράς του μοντέλου. Η ποσοτικοποίηση της σημασίας κάθε χαρακτηριστικού πραγματοποιήθηκε μέσω του μέσου όρου και της τυπικής απόκλισης των απόλυτων τιμών SHAP, όπως παρουσιάζονται στους ακόλουθους πίνακες. Οι τιμές αυτές παρέχουν μια συνοπτική αλλά ουσιαστική αποτίμηση της σχετικής συμβολής των εισόδων στις προβλέψεις του μοντέλου, καθώς ο μέσος όρος $\text{mean}(|\phi|)$ εκφράζει τη συνολική σημασία, ενώ η τυπική απόκλιση $\text{std}(|\phi|)$ αποτυπώνει τη διασπορά της επίδρασης στα διαφορετικά δείγματα.

Εν συνεχεία, παραθέτονται τα SHAP summary plots για κάθε μια από τις 8 εξόδους ξεχωριστά:




Σχήμα 4.3: Phase Margin

Πίνακας 4.3: Μέσες τιμές και τυπικές αποκλίσεις SHAP για την Έξοδο 1 Phase Margin

Χαρακτηριστικό	Μέση Τιμή SHAP	Τυπική Απόκλιση
Cc	0.4696	0.3411
Wbp	0.3909	0.5488
Wdiff	0.4321	0.3255
Wnb	0.0481	0.0348
Wpo	0.3485	0.1882

Στην Έξοδο 1 Phase Margin παρατηρείται ότι οι παράμετροι Cc (0.47 ± 0.34), Wbp (0.39 ± 0.55) και Wdiff (0.43 ± 0.33) εμφανίζουν παρόμοια επίπεδα σημαντικότητας, γεγονός που δείχνει ότι επηρεάζουν εξίσου την πρόβλεψη. Η παράμετρος Wpo (0.35 ± 0.19) έχει μικρότερη αλλά υπολογίσιμη συμβολή, ενώ η Wnb παρουσιάζει την ελάχιστη επίδραση (0.05 ± 0.03). Στο διάγραμμα διασποράς των τιμών SHAP παρατηρείται σχετικά συμμετρική κατανομή, όπου θετικές τιμές αντιστοιχούν σε αύξηση της πρόβλεψης και αρνητικές σε μείωση, χωρίς ακραίες αποκλίσεις. Αυτό το μοτίβο συμφωνεί με τη θεωρία του τελεστικού, σύμφωνα με την οποία το περιθώριο φάσης βελτιώνεται όταν η χωρητικότητα αντιστάθμισης C_c επιτυγχάνει επαρκές pole splitting, ενώ οι γεωμετρικές παράμετροι των βαθμίδων (όπως Wbp και Wdiff) επηρεάζουν τα g_m και r_o και συνεπώς τις θέσεις των πόλων.




Σχήμα 4.4: Unity Gain

Πίνακας 4.4: Μέσες τιμές και τυπικές αποκλίσεις SHAP για την Έξοδο 2 Unity Gain

Χαρακτηριστικό	Μέση Τιμή SHAP	Τυπική Απόκλιση
Cc	0.7926	0.5723
Wbp	0.2189	0.3124
Wdiff	0.3184	0.2463
Wnb	0.0285	0.0249
Wpo	0.1380	0.1089

Στην Έξοδο 2 Unity Gain Bandwidth κυρίαρχη σημασία έχει η παράμετρος C_c (0.79 ± 0.57), η οποία επηρεάζει άμεσα την τιμή της εξόδου: υψηλές τιμές C_c συνδέονται με θετική επίδραση, ενώ χαμηλές με αρνητική. Οι παράμετροι W_{bp} και W_{diff} έχουν δευτερεύουσα συνεισφορά, ενώ οι W_{po} και W_{nb} παίζουν ελάχιστο ρόλο. Στο διάγραμμα παρατηρείται ευρεία κατανομή των σημείων, με ορισμένες ακραίες τιμές, που δείχνουν ότι η C_c μπορεί να καθορίσει σε μεγάλο βαθμό τη διακύμανση της εξόδου. Όπως αναμένεται από τη θεωρία, το εύρος ζώνης μοναδιαίου κέρδους ($UGBW$) προσεγγίζει g_{m1}/C_c , γεγονός που εξηγεί γιατί η C_c εμφανίζεται κυρίαρχη στις προβλέψεις. Αξίζει επίσης να σημειωθεί ότι το πρόσημο των τιμών SHAP έχει σαφή φυσική ερμηνεία: υψηλές τιμές της C_c (κόκκινα σημεία) αντιστοιχούν κυρίως σε αρνητικές τιμές SHAP, δηλαδή συμβάλλουν σε μείωση του $UGBW$, ενώ χαμηλές τιμές της C_c (μπλε σημεία) οδηγούν σε θετικές τιμές SHAP, συμβάλλοντας σε αύξηση του $UGBW$.



Σχήμα 4.5: Gain

Πίνακας 4.5: Μέσες τιμές και τυπικές αποκλίσεις SHAP για την Έξοδο 3 Gain

Χαρακτηριστικό	Μέση Τιμή SHAP	Τυπική Απόκλιση
Cc	0.0282	0.0267
Wbp	0.4568	0.5250
Wdiff	0.0874	0.0799
Wnb	0.0660	0.0431
Wpo	0.3430	0.2518

Στην Έξοδο 3 Gain η παράμετρος Wbp είναι η πλέον σημαντική (0.46 ± 0.53), ενώ σημαντική συνεισφορά έχει και η Wpo (0.34 ± 0.25). Οι υπόλοιπες παράμετροι έχουν μικρότερη σημασία, με την Cc να εμφανίζεται σχεδόν αμελητέα. Η κατανομή των σημείων δείχνει ότι χαμηλές τιμές της Wbp συνδέονται με έντονη αρνητική επίδραση, ενώ υψηλές τιμές μετατοπίζουν την πρόβλεψη προς το θετικό μέρος, φανερώνοντας μη γραμμική σχέση. Η εικόνα αυτή είναι σύμφωνη με τη θεωρία, σύμφωνα με την οποία το DC κέρδος ανοικτού βρόχου εξαρτάται από το γινόμενο των g_m και r_o των βαθμίδων, επομένως οι γεωμετρικές παράμετροι Wbp και Wpo παίζουν πρωτεύοντα ρόλο, ενώ η C_c δεν επηρεάζει σημαντικά τη στατική ενίσχυση. Πιο συγκεκριμένα, το κέρδος ανοικτού βρόχου μπορεί να προσεγγιστεί από τη σχέση $A_v \approx g_m \cdot r_o$, όπου g_m είναι η διαγωγιμότητα και r_o η αντίσταση εξόδου του MOSFET. Η διαγωγιμότητα ορίζεται ως

$$g_m = \frac{\partial I_D}{\partial V_{GS}} \approx \frac{2I_D}{V_{OV}},$$

όπου I_D είναι το **ρεύμα καναλιού (drain current)** και $V_{OV} = V_{GS} - V_{TH}$ η υπέρταση πύλης. Η αντίσταση εξόδου δίνεται από

$$r_o \approx \frac{1}{\lambda I_D},$$


όπου λ είναι ο **συντελεστής εξάρτησης από το μήκος καναλιού (channel-length modulation parameter)**. Από τις παραπάνω σχέσεις γίνεται σαφές ότι το κέρδος εξαρτάται άμεσα από το ρεύμα καναλιού και τις γεωμετρικές διαστάσεις W/L των τρανζίστορ, καθώς οι παράμετροι αυτές καθορίζουν τόσο το g_m όσο και το r_o . Πιο συγκεκριμένα,

για MOSFET σε περιοχή κόρου ισχύει:

$$I_D = \frac{1}{2} \mu C_{ox} \frac{W}{L} (V_{OV})^2,$$

οπότε, για σταθερό V_{OV} , το ρεύμα καναλιού είναι ανάλογο του πλάτους W . Συνεπώς, στη βαθμίδα πόλωσης, το ρεύμα I_D αυξάνεται γραμμικά με το W_{bp} , οδηγώντας και σε αύξηση της διαγωγιμότητας g_m , αφού $g_m \approx 2I_D/V_{OV}$. Στο στάδιο εξόδου, η παράμετρος W_{po} καθορίζει το ρεύμα I_D . Για σταθερό V_{OV} , αύξηση του W_{po} αυξάνει το I_D , γεγονός που μειώνει το r_o . Έτσι, το W_{po} επηρεάζει κυρίως το r_o και μέσω αυτού το κέρδος ανοικτού βρόχου.

Αξίζει να σημειωθεί ότι, αν το ρεύμα εξόδου I_D διατηρείται σταθερό μέσω πόλου ρεύματος, τότε το r_o δεν αλλάζει με το W_{po} . Σε αυτήν την περίπτωση, η μεταβολή του W_{po} μειώνει την υπέρταση V_{OV} , αυξάνοντας έτσι το $g_m = 2I_D/V_{OV}$. Δηλαδή, το W_{po} μπορεί να επηρεάζει το $A_v = g_m r_o$ είτε μέσω του r_o είτε μέσω του g_m , ανάλογα με τις συνθήκες πόλωσης. Έτσι, ερμηνεύεται γιατί οι παράμετροι W_{bp} και W_{po} έχουν καθοριστική συμβολή στον προσδιορισμό του Gain, ενώ η χωρητικότητα αντιστάθμισης C_c δεν επηρεάζει σημαντικά τη στατική ενίσχυση.




Σχήμα 4.6: ICMR max

Πίνακας 4.6: Μέσες τιμές και τυπικές αποκλίσεις SHAP για την Έξοδο 4 ICMR_max

Χαρακτηριστικό	Μέση Τιμή SHAP	Τυπική Απόκλιση
Cc	0.0359	0.0753
Wbp	0.6865	0.7063
Wdiff	0.0610	0.0526
Wnb	0.0877	0.0563
Wpo	0.0209	0.0208

Η Έξοδος 4 ICMR-max επηρεάζεται σχεδόν αποκλειστικά από την παράμετρο W_{bp} (0.69 ± 0.71), η οποία παρουσιάζει μεγάλη διασπορά, δείχνοντας ότι οι διαφορετικές τιμές της μεταβάλλουν έντονα την πρόβλεψη. Οι υπόλοιπες παράμετροι έχουν πολύ χαμηλή σημασία. Η κατανομή των σημείων είναι ασύμμετρη: χαμηλές τιμές της W_{bp} συνδέονται με αρνητική συμβολή, ενώ υψηλές με θετική, κάτι που καταδεικνύει τον καθοριστικό ρόλο της στη διαμόρφωση της εξόδου. Αυτό συνδέεται άμεσα με τη θεωρία,

καθώς το άνω όριο του κοινού σήματος καθορίζεται από το headroom (περιθώριο τάσης) προς V_{DD} και τα V_{OV} των PMOS τρανζίστορ του άνω κλάδου του κυκλώματος· συνεπώς, η επίδραση της W_{bp} είναι αναμενόμενη.




Σχήμα 4.7: ICMR min

Πίνακας 4.7: Μέσες τιμές και τυπικές αποκλίσεις SHAP για την Έξοδο 5 ICMR_min

Χαρακτηριστικό	Μέση Τιμή SHAP	Τυπική Απόκλιση
Cc	0.0122	0.0099
Wbp	0.0271	0.0280
Wdiff	0.7302	0.5518
Wnb	0.7162	0.3857
Wpo	0.0184	0.0165

Στην Έξοδο 5 ICMR-min οι σημαντικότερες παράμετροι είναι οι W_{diff} (0.73 ± 0.55) και W_{nb} (0.72 ± 0.39), που καθορίζουν σε μεγάλο βαθμό την έξοδο. Η W_{diff} παρουσιάζει συμμετρική κατανομή γύρω από το μηδέν, με θετικές και αρνητικές τιμές να κατανέμονται ισομερώς, ενώ η W_{nb} έχει έντονη θετική επίδραση όταν λαμβάνει υψηλές τιμές. Οι υπόλοιπες παράμετροι έχουν αμελητέα σημασία. Η συμπεριφορά αυτή αντανάκλα τη θεωρητική πρόβλεψη ότι το κάτω όριο κοινού σήματος περιορίζεται από τα V_{OV} του διαφορικού ζεύγους και της κάτω πηγής ρεύματος· άρα, οι γεωμετρικές παράμετροι W_{diff} και W_{nb} καθορίζουν το ICMR_min.




Σχήμα 4.8: Vout max

Πίνακας 4.8: Μέσες τιμές και τυπικές αποκλίσεις SHAP για την Έξοδο 6 Vout_max

Χαρακτηριστικό	Μέση Τιμή SHAP	Τυπική Απόκλιση
Cc	0.0407	0.0894
Wbp	0.6157	0.7290
Wdiff	0.0958	0.1156
Wnb	0.0739	0.0518
Wpo	0.0842	0.0550

Η Έξοδος 6 Vout_max εξαρτάται κυρίως από την παράμετρο Wbp (0.62 ± 0.73), που παρουσιάζει τη μεγαλύτερη διακύμανση. Στο διάγραμμα φαίνεται ότι χαμηλές τιμές Wbp έχουν αρνητική συμβολή, ενώ υψηλές τιμές οδηγούν σε θετική. Οι υπόλοιπες παράμετροι συμβάλλουν ελάχιστα, με την Cc να δείχνει περιορισμένη αλλά σαφή θετική τάση. Η διαπίστωση αυτή συμφωνεί με τη θεωρία, σύμφωνα με την οποία το μέγιστο swing προς V_{DD} περιορίζεται από το $V_{OV,p}$ της βαθμίδας εξόδου, το οποίο μειώνεται όσο αυξάνεται το W/L της Wbp. Αυτό οφείλεται στο γεγονός ότι η Wbp καθορίζει το ρεύμα πόλωσης του κυκλώματος, το οποίο με τη σειρά του ρυθμίζει το $V_{OV,p}$ της βαθμίδας εξόδου. Έτσι, μέσω της πόλωσης, η Wbp συνδέεται άμεσα με το μέγιστο swing τάσης προς V_{DD} .




Σχήμα 4.9: Vout min

Πίνακας 4.9: Μέσες τιμές και τυπικές αποκλίσεις SHAP για την Έξοδο 7 V_{out_min}

Χαρακτηριστικό	Μέση Τιμή SHAP	Τυπική Απόκλιση
Cc	0.0104	0.0089
Wbp	0.0090	0.0092
Wdiff	0.0479	0.0408
Wnb	0.9050	0.4800
Wpo	0.0110	0.0101

Η Έξοδος 7 V_{out_min} κυριαρχείται απόλυτα από την παράμετρο Wnb (0.91 ± 0.48), με τα υπόλοιπα χαρακτηριστικά να έχουν πρακτικά μηδενική σημασία. Η κατανομή δείχνει ότι υψηλές τιμές Wnb οδηγούν σε σημαντική θετική επίδραση, ενώ χαμηλές σε αρνητική. Το διάγραμμα αποτυπώνει καθαρά τη μονοδιάστατη εξάρτηση της εξόδου από αυτήν την παράμετρο. Αυτό είναι σε συμφωνία με τη θεωρία, καθώς το ελάχιστο swing προς V_{SS} καθορίζεται από το $V_{OV,n}$ του «κάτω» τρανζίστορ· μεγαλύτερο W/L οδηγεί σε μικρότερο $V_{OV,n}$ και άρα χαμηλότερο V_{out_min} .



Σχήμα 4.10: Slew Rate

Πίνακας 4.10: Μέσες τιμές και τυπικές αποκλίσεις SHAP για την Έξοδο 8 Slew Rate

Χαρακτηριστικό	Μέση Τιμή SHAP	Τυπική Απόκλιση
Cc	0.8437	0.6300
Wbp	0.0499	0.0613
Wdiff	0.1184	0.1021
Wnb	0.0519	0.0370
Wpo	0.0224	0.0283

Στην Έξοδο 8 Slew Rate η παράμετρος Cc είναι καθοριστική (0.84 ± 0.63), υπερέχοντας όλων των άλλων. Η κατανομή δείχνει ότι υψηλές τιμές Cc συνδέονται με θετική συμβολή, ενώ χαμηλές με αρνητική, αποτυπώνοντας καθαρή σχέση εξάρτησης. Τα υπόλοιπα χαρακτηριστικά έχουν δευτερεύουσα ή αμελητέα σημασία. Η κυριαρχία αυτή της Cc συμβαδίζει με τη θεωρία, καθώς ο ρυθμός μεταβολής δίνεται από $SR \approx I_5/C_c$, οπότε η χωρητικότητα αντιστάθμισης είναι ο καθοριστικός παράγοντας.

Πιο συγκεκριμένα, οι μέσοι όροι και οι τυπικές αποκλίσεις των τιμών SHAP ανά χαρακτηριστικό (για κάθε έξοδο) επιβεβαιώνουν τη σημαντικότητα των λειτουργικών παραμέτρων, όπως οι διαστάσεις των τρανζίστορ και οι τάσεις πόλωσης, στη συνολική απόδοση του μοντέλου.

Κεφάλαιο 5

Συμπεράσματα

Η παρούσα εργασία εστίασε στην ανάπτυξη και ερμηνεία ενός τεχνητού νευρωνικού δικτύου για την πρόβλεψη βασικών μετρικών απόδοσης ενός τελεστικού ενισχυτή. Ο κεντρικός στόχος ήταν διττός: αφενός η κατασκευή ενός αξιόπιστου μοντέλου πρόβλεψης που να μειώνει την εξάρτηση από τις χρονοβόρες και υπολογιστικά απαιτητικές προσομοιώσεις τύπου SPICE, και αφετέρου η σε βάθος κατανόηση των παραμέτρων που επηρεάζουν περισσότερο την απόδοση του κυκλώματος, μέσα από τη χρήση μεθόδων εξηγούμενης τεχνητής νοημοσύνης.

Η εκπαίδευση του μοντέλου, η οποία υλοποιήθηκε στο περιβάλλον PyTorch, ανέδειξε την ικανότητά του να αποτυπώνει με επάρκεια τις μη γραμμικές σχέσεις μεταξύ εισόδων και εξόδων. Το υψηλό επίπεδο ακρίβειας που επιτεύχθηκε στο σύνολο ελέγχου (με $R^2 \approx 0.91$) επιβεβαιώνει ότι τα νευρωνικά δίκτυα μπορούν να αποτελέσουν μια αποτελεσματική εναλλακτική προσέγγιση στις κλασικές μεθόδους προσομοίωσης.

Η ανάλυση ερμηνευσιμότητας μέσω των τιμών SHAP επέτρεψε την ποσοτική αποτίμηση της συμβολής κάθε εισόδου στις τελικές προβλέψεις του μοντέλου, ενισχύοντας τη διαφάνεια και την αξιοπιστία της διαδικασίας. Τα αποτελέσματα κατέδειξαν ότι διαφορετικές μετρικές απόδοσης επηρεάζονται σε διαφορετικό βαθμό από τις επιμέρους παραμέτρους: η χωρητικότητα σύζευξης (C_c) αποδείχθηκε καθοριστική για μετρικές όπως το Unity Gain και το Slew Rate, ενώ η παράμετρος W_{bp} διαδραματίζει πρωτεύοντα ρόλο σε μετρικές όπως το $ICMR_{max}$ και η μέγιστη τάση εξόδου. Παράλληλα, οι παράμετροι W_{diff} και W_{nb} αναδείχθηκαν ως κρίσιμοι παράγοντες για το $ICMR_{min}$ και την ελάχιστη τάση εξόδου. Η διαφοροποίηση αυτή υπογραμμίζει τη σημασία της πολυπαραγοντικής ανάλυσης, καθώς η απόδοση ενός τελεστικού ενισχυτή δεν εξαρτάται μονοδιάστατα από μία μόνο μεταβλητή.

Η συμβολή της μεθόδου SHAP δεν περιορίζεται απλώς στην αποσαφήνιση των προβλέψεων του μοντέλου, αλλά εκτείνεται και στη δυνατότητα ενσωμάτωσης των ερμηνειών αυτών σε διαδικασίες σχεδιαστικής βελτιστοποίησης. Σε σύγκριση με τις παραδοσιακές προσομοιώσεις, η προτεινόμενη προσέγγιση προσφέρει σημαντικά πλεονεκτήματα ως προς την ταχύτητα και την ερμηνευσιμότητα, χωρίς να θυσιάζει την ακρίβεια. Ως εκ

τούτου, η χρήση νευρωνικών δικτύων σε συνδυασμό με μεθόδους εξηγούμενης τεχνητής νοημοσύνης μπορεί να αποτελέσει ιδιαίτερα χρήσιμο εργαλείο στον αρχικό σχεδιασμό και στην ανάλυση αναλογικών ολοκληρωμένων κυκλωμάτων.

Συνολικά, τα ευρήματα της εργασίας επιβεβαιώνουν ότι η αξιοποίηση σύγχρονων τεχνικών μηχανικής μάθησης μπορεί να ενισχύσει ουσιαστικά το πεδίο της μικροηλεκτρονικής. Η δυνατότητα πρόβλεψης με υψηλή ακρίβεια, σε συνδυασμό με την ερμηνευσιμότητα που παρέχει η μέθοδος SHAP, συνιστά μια καινοτόμο κατεύθυνση, η οποία μπορεί να διευκολύνει τον σχεδιασμό αποδοτικότερων και πιο αξιόπιστων κυκλωμάτων.

Μελλοντικές Επεκτάσεις

Παρά τα ενθαρρυντικά αποτελέσματα, η έρευνα αφήνει περιθώρια για περαιτέρω διερεύνηση. Ένα πρώτο βήμα συνίσταται στη διεύρυνση του συνόλου δεδομένων, ώστε να καλύπτει μεγαλύτερο εύρος παραμέτρων και αρχιτεκτονικών κυκλωμάτων, αυξάνοντας έτσι τη γενικευσιμότητα του μοντέλου. Παράλληλα, η μελέτη πιο σύνθετων αρχιτεκτονικών νευρωνικών δικτύων, όπως συνελκτικών ή αναδρομικών, θα μπορούσε να αποκαλύψει βαθύτερα πρότυπα και αλληλεπιδράσεις. Επιπλέον, η σύγκριση της μεθόδου SHAP με άλλες τεχνικές ερμηνευσιμότητας, όπως η LIME ή τα Integrated Gradients, θα προσέφερε μια πιο ολοκληρωμένη εικόνα για τα πλεονεκτήματα και τους περιορισμούς κάθε μεθοδολογίας. Τέλος, η ενσωμάτωση της παρούσας προσέγγισης σε αυτοματοποιημένα εργαλεία σχεδιασμού μπορεί να επιταχύνει σημαντικά τις διαδικασίες βελτιστοποίησης, καθιστώντας την τεχνητή νοημοσύνη αναπόσπαστο κομμάτι του σχεδιασμού αναλογικών ολοκληρωμένων κυκλωμάτων.

Η εργασία αυτή αποδεικνύει ότι η διασταύρωση της μηχανικής μάθησης με την εξηγούμενη τεχνητή νοημοσύνη ανοίγει νέες προοπτικές στον χώρο της μικροηλεκτρονικής. Η συμβολή της δεν έγκειται μόνο στην αύξηση της αποδοτικότητας, αλλά και στην ενίσχυση της κατανόησης, στοιχείο απαραίτητο για την εξέλιξη καινοτόμων και αξιόπιστων τεχνολογιών.

Κεφάλαιο 6

Βιβλιογραφία

Bibliography

- [6.1] J. Wei, Y. Zeng, and X. Liu, “An enhanced operational amplifier macro model based on artificial neural network,” *International Journal of Circuit Theory and Applications*, 50(12): 5742–5755, 2022. DOI: <https://doi.org/10.1002/cta.3381>.
- [6.2] J. P. da Silva Rosa, *Using Artificial Neural Networks to Size Analog Integrated Circuits*, M.Sc. Dissertation, Instituto Superior Técnico, Universidade de Lisboa, 2018. Available: https://fenix.tecnico.ulisboa.pt/downloadFile/844820067125542/Dissertation_74149.pdf.
- [6.3] S. Rakhimov, M. Shahid, and A. Riaz, “Machine Learning Driven Global Optimisation Framework for Analog Circuit Design,” *arXiv:2404.02911*, 2024. Available: <https://arxiv.org/abs/2404.02911>.
- [6.4] A. Wang and X. Tang (eds.), “Using Artificial Neural Networks for Analog Integrated Circuits Design,” in *Automatic Sizing and Layout of Analog ICs using Deep Learning*, Springer, 2020. Available (chapter PDF): <https://link.springer.com/content/pdf/10.1007/978-3-030-35743-6.pdf>.
- [6.5] A. Esteva, A. Robicquet, B. Ramsundar, V. Kuleshov, M. DePristo, K. Chou, C. Cui, G. Corrado, S. Thrun, and J. Dean, “A guide to deep learning in healthcare,” *Nature Medicine*, 25(1):24–29, 2019. DOI: <https://doi.org/10.1038/s41591-018-0316-z>. Available: <https://www.nature.com/articles/s41591-018-0316-z>.
- [6.6] S. Grigorescu, B. Trasnea, T. Cocias, and G. Macesanu, “A survey of deep learning techniques for autonomous driving,” *Journal of Field Robotics*, 37(3):362–386, 2020. DOI: <https://doi.org/10.1002/rob.21918>. Available: <https://onlinelibrary.wiley.com/doi/abs/10.1002/rob.21918>.
- [6.7] T. Fischer and C. Krauss, “Deep learning with long short-term memory networks for financial market predictions,” *European Journal of Operational Research*, 270(2):654–669, 2018. DOI: <https://doi.org/10.1016/j.ejor.2017.11.054>. Available: <https://www.sciencedirect.com/science/article/pii/S0377221717310652>.
- [6.8] M. T. Ribeiro, S. Singh, and C. Guestrin, “Why Should I Trust You? Explaining the Predictions of Any Classifier,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1135–1144, 2016. DOI: <https://doi.org/10.1145/2939672.2939778>. Available: <https://dl.acm.org/doi/10.1145/2939672.2939778>.
- [6.9] M. Sundararajan, A. Taly, and Q. Yan, “Axiomatic Attribution for Deep Networks,” in *International Conference on Machine Learning (ICML)*, PMLR, pp. 3319–3328, 2017. Available: <https://proceedings.mlr.press/v70/sundararajan17a.html> (PDF: <https://proceedings.mlr.press/v70/sundararajan17a/sundararajan17a.pdf>).
- [6.10] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 618–626, 2017. Available (OpenAccess PDF): https://openaccess.thecvf.com/content_ICCV_2017/papers/Selvaraju_Grad-CAM_Visual_Explanations_ICCV_2017_paper.pdf.

- [6.11] W. McKinney, “Data Structures for Statistical Computing in Python,” in *Proceedings of the 9th Python in Science Conference (SciPy)*, S. van der Walt and J. Millman (eds.), pp. 51–56, 2010. Available: <https://conference.scipy.org/proceedings/scipy2010/mckinney.html> (PDF mirror: <https://proceedings.scipy.org/articles/proceedings-2010.pdf>).
- [6.12] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, *et al.*, “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 32:8024–8035, 2019. Available: <https://papers.nips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library> (PDF: <https://papers.neurips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library.pdf>).
- [6.13] D. P. Kingma and J. Ba, “Adam: A Method for Stochastic Optimization,” in *International Conference on Learning Representations (ICLR)*, 2015. Available: <https://arxiv.org/abs/1412.6980>.
- [6.14] IBM, “Neural Networks — IBM Think,” 2023. Available: <https://www.ibm.com/think/topics/neural-networks> (Accessed: Aug. 27, 2025).
- [6.15] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016. Available: <https://www.deeplearningbook.org/>.
- [6.16] L. W. Nagel, “SPICE2: A Computer Program to Simulate Semiconductor Circuits,” UCB/ERL Memorandum M520, University of California, Berkeley, 1975. Available: <https://www2.eecs.berkeley.edu/Pubs/TechRpts/1975/ERL-m-520.pdf>. latex
- [6.17] W. Liu, X. Jin, K. M. Cao, and C. Hu, “BSIM4.1.0 MOSFET Model — User’s Manual,” UCB/ERL M00/48, University of California, Berkeley, Oct. 2000. Available: <https://www2.eecs.berkeley.edu/Pubs/TechRpts/2000/ERL-00-48.pdf>.
- [6.18] L. S. Shapley, “A Value for n-Person Games,” in *Contributions to the Theory of Games II* (Annals of Mathematics Studies, No. 28), Princeton University Press, 1953, pp. 307–317. latex
- [6.19] S. M. Lundberg and S.-I. Lee, “A Unified Approach to Interpreting Model Predictions,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017. Available: <https://arxiv.org/abs/1705.07874>.
- [6.20] S. M. Lundberg and S.-I. Lee, “A Unified Approach to Interpreting Model Predictions,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017. Available: <https://arxiv.org/abs/1705.07874> (PDF: <https://proceedings.neurips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions.pdf>).
- [6.21] I. Covert and S.-I. Lee, “Improving KernelSHAP: Practical Shapley Value Estimation Using Linear Regression,” in *Proceedings of the 24th International Conference on Artificial Intelligence and Statistics (AISTATS)*, vol. 130, pp. 3457–3465, 2021. Available: <https://arxiv.org/abs/2012.01536> (PDF: <https://proceedings.mlr.press/v130/covert21a/covert21a.pdf>).
- [6.22] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. Available: <https://jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf>

List of Figures

2.1	Αρχιτεκτονική ενός τυπικού νευρωνικού δικτύου [14].	9
3.1	Κύκλωμα Τελεστικού Ενισχυτή.	15
3.2	Καμπύλη σύγκλισης της συνάρτησης κόστους (MSE) κατά την εκπαίδευση του νευρωνικού δικτύου για 3000 εποχές.	19
4.1	Σύγκριση πραγματικών και προβλεπόμενων τιμών μετρικών απόδοσης στο σύνολο ελέγχου.	22
4.2	SHAP summary plot για την έξοδο του μοντέλου.	23
4.3	Phase Margin	25
4.4	Unity Gain	26
4.5	Gain	27
4.6	ICMR max	28
4.7	ICMR min	29
4.8	Vout max	30
4.9	Vout min	30
4.10	Slew Rate	31